UNIVERSIDAD POLITECNICA SALESIANA

CARRERA: Computación
ASIGNATURA: Simulación
NRO. PRUEBA: 1
ESTUDIANTE: Bryam Barrera

ACTIVIDADES DESARROLLADAS

- **Importamos las librerias necesarias**

```
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import io
import statistics
from google.colab import files
import plotly.graph_objects as go
import altair as alt
import plotly.express as px
import plotly
plotly.offline.init_notebook_mode(connected=True)
import seaborn as sns
```

Generar gráficas para entender y procesar los datos:

- **Graficas y reportes del total de personas empleadas y desempleadas por año.**

```
poblaciones = pd.read_csv("/content/1.Poblaciones.csv",skiprows=2, low_memory=False,enc
#imprimir los primeros 5 datos del archivo

print(poblaciones)
```

```
     Encuesta     Periodo  ...   Hombre    Mujer
0     ENEMDU  12/01/2007  ...  6768646  6913656
1     ENEMDU  12/01/2007  ...  2226618  2146194
2     ENEMDU  12/01/2007  ...  4542028  4767462
3     ENEMDU  12/01/2007  ...  3777232  2558798
4     ENEMDU  12/01/2007  ...  3632314  2387018
..       ...         ...  ...      ...      ...
895  ENEMDU*  10/01/2021  ...   150276   185824
896  ENEMDU*  10/01/2021  ...    25975    22128
897  ENEMDU*  10/01/2021  ...   140223   158623
898  ENEMDU*  10/01/2021  ...    36028    49330
899  ENEMDU*  10/01/2021  ...  1324745  3005495
```

```
[900 rows x 8 columns]
```

- **Filtración de datos:** Filtramos el total de la población empleo y desempleo que existe en el conjunto de datos.

```
empleo=poblaciones.loc[ (poblaciones['Unnamed: 2']) == 'Empleo']
desempleo=poblaciones.loc[ (poblaciones['Unnamed: 2']) == 'Desempleo']
```

- **Para manejar de mejor manera el dataframe extraemos el año y lo adicionamos en una nueva columna**

```
def sacAnio(anio):
  return str(anio).split("/")[2]

empleo["Anios"]=empleo.apply(lambda x: sacAnio(x[1]), axis=1)
desempleo["Anios"]=desempleo.apply(lambda x: sacAnio(x[1]), axis=1)
```

```
/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:4: SettingWithCopyWarnir


A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/us

/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:5: SettingWithCopyWarnir


A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/us
```

```
empleo.head()
```

	Encuesta	Periodo	Unnamed: 2	Total	Urbana	Rural	Hombre	Mujer	An
4	ENEMDU	12/01/2007	Empleo	6019332	3971040	2048292	3632314	2387018	2
22	ENEMDU	06/01/2008	Empleo	6245225	4151002	2094223	3742213	2503012	2
40	ENEMDU	12/01/2008	Empleo	6005395	4012298	1993097	3635236	2370159	2
58	ENEMDU	12/01/2009	Empleo	6125135	4050179	2074956	3699840	2425296	2
76	ENEMDU	06/01/2010	Empleo	6174141	4075417	2098724	3716323	2457818	2

```
desempleo.head()
```

	Encuesta	Periodo	Unnamed: 2	Total	Urbana	Rural	Hombre	Mujer	Anios
12	ENEMDU	12/01/2007	Desempleo	316697	256662	60036	144918	171780	2007
30	ENEMDU	06/01/2008	Desempleo	344143	282489	61654	151283	192860	2008
48	ENEMDU	12/01/2008	Desempleo	380026	317011	63015	165296	214730	2008
66	ENEMDU	12/01/2009	Desempleo	423802	347068	76734	201625	222177	2009

- **Aqui podemos observar como se guardaron los años en la columna creada**

```
anios_empleo=empleo.iloc[:,-1]
anios_empleo=anios_empleo.unique()
print(anios_empleo)
```

```
['2007' '2008' '2009' '2010' '2011' '2012' '2013' '2014' '2015' '2016'
 '2017' '2018' '2019' '2020' '2021']
```

- **Creamos una función que permite realizar una búsqueda en los registros del dataset**

```
#Funcion de Busqueda
def search_value_desemp(param,key,val):
  if param==key:
    return val

#Creacion de diccionarios y busqueda de datos
list_vals_emp_anio=[]
list_vals_desemp_anio=[]
dic_empleo={}
dic_desempleo={}

#Procedemos ha realizar la búsqueda en función de todos los años,
#tanto en el dataframe de empleo y del de desempleo de paso procedemos
#a realizar un promedio en base a los datos porque existen cifras
#por cada mes reduciendo la información a intervalos por año
for i in anios_empleo:
  df_Emp=empleo.apply(lambda x:search_value_desemp(i,x[8],x[3]),axis=1)
  df_Emp=df_Emp.dropna()
  dic_empleo.setdefault(i,df_Emp.mean())

for i in anios_empleo:
  df_Emp=desempleo.apply(lambda x:search_value_desemp(i,x[8],x[3]),axis=1)
  df_Emp=df_Emp.dropna()
  dic_desempleo.setdefault(i,df_Emp.mean())

print('**EMPLEO**:','[',dic_empleo,']')
print('**DESEMPELO**:','[',dic_desempleo,']')
```

```
**EMPLEO**: [ {'2007': 6019332.0, '2008': 6125310.0, '2009': 6125135.0, '2010': 61436
**DESEMPELO**: [ {'2007': 316697.0, '2008': 362084.5, '2009': 423802.0, '2010': 36567
```

- **Creamos un dataset el cual contenga todos los años y sus valores**

```
empleo=pd.DataFrame(dic_empleo.items())
empleo.columns=['Años','Empleo']

desempleo=pd.DataFrame(dic_desempleo.items())
desempleo.columns=['Años','Desempleo']

empleo["Desempleo"]=desempleo.iloc[:,-1]
empleo.head()
```

	Años	Empleo	Desempleo
0	2007	6019332.0	316697.0
1	2008	6125310.0	362084.5
2	2009	6125135.0	423802.0
3	2010	6143685.5	365672.5
4	2011	6264709.0	302996.0

```
from google.colab import drive
drive.mount('/content/drive')
```

```
Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.m
```

- **Grafico de comparacion de Empelos y Desempleos**

```
plt.figure(figsize=(15,10))
plt.grid(True)

plt.plot(empleo['Años'], empleo['Empleo'], label='Empleo')
plt.plot(desempleo['Años'], desempleo['Desempleo'], label='Desempleo')

plt.title('Comparación de la cantidad de personas empleadas y desempleadas')
try:
    plt.ticklabel_format(style='plain')
except AttributeError:
    print('')
plt.legend(loc='upper left')
plt.show()
```

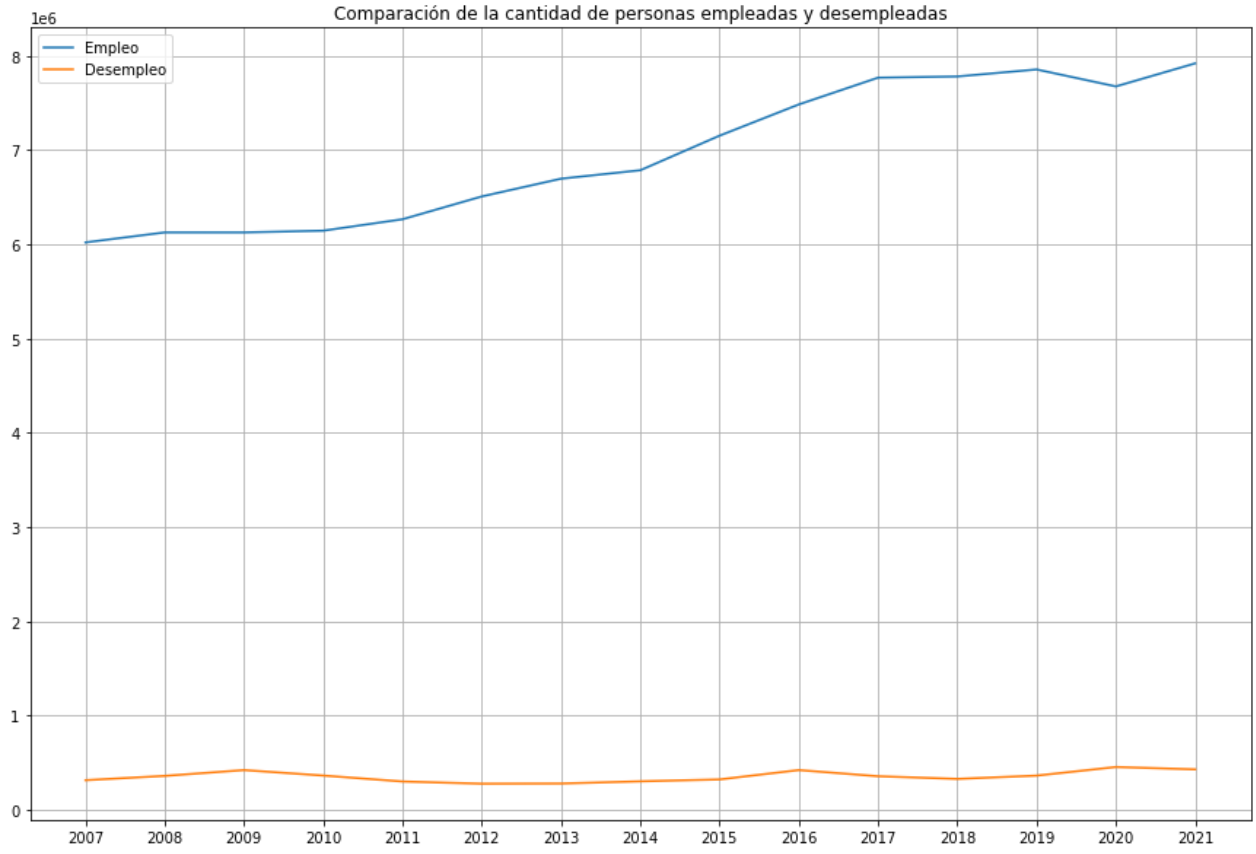

- **Gráfico de pie por personas basadas en la secrización de empleo**

```
sec= pd.read_csv("drive/MyDrive/Prueba/Sectoriza.csv",skiprows=0, low_memory=False,enco
sec=sec.iloc[0:5]
sec=sec.transpose()
sec.columns=sec.iloc[1]
sec=sec.iloc[2:]
sec.head()
sec.to_csv('drive/MyDrive/Prueba/datos.csv',encoding= 'latin1')
```

```
sec= pd.read_csv("drive/MyDrive/Prueba/datos.csv",skiprows=0, low_memory=False,encoding
sec.head(20)
```

	Unnamed: 0	Unnamed: 1	Sector Formal	Sector Informal	Empleo Doméstico	No Clasificados por Sector
0	Unnamed: 2	06/01/2007	-	-	-	-
1	Unnamed: 3	09/01/2007	-	-	-	-
2	Unnamed: 4	12/01/2007	41%	45.1%	3.3%	10.6%
3	Unnamed: 5	03/01/2008	-	-	-	-
4	Unnamed: 6	06/01/2008	42.5%	45.4%	3.3%	8.8%
5	Unnamed: 7	09/01/2008	-	-	-	-
6	Unnamed: 8	12/01/2008	43.9%	43.5%	3.5%	9.2%

- **Para manejar de mejor manera el dataframe extraemos el año y lo adicionamos en una nueva columna**

```
sec["Anios"]=sec.apply(lambda x: sacAnio(x[1]), axis=1)
sec.head()
```

	Unnamed: 0	Unnamed: 1	Sector Formal	Sector Informal	Empleo Doméstico	No Clasificados por Sector	Anios
0	Unnamed: 2	06/01/2007	-	-	-	-	2007
1	Unnamed: 3	09/01/2007	-	-	-	-	2007
2	Unnamed: 4	12/01/2007	41%	45.1%	3.3%	10.6%	2007

- **Creamos una función que permite realizar una búsqueda en los registros del dataset**

```
def search_value_sec(param,key,secF,secIn,empD,noClass):
  if param==key:
    return float(secF.strip('%')),float(secIn.strip('%')),float(empD.strip('%')),float(
```

```
def sectorizacion(rang1,rang2):
  dfF=pd.DataFrame()
  for i in range(rang1,rang2):
```

```
    dfT=sec.apply(lambda x: search_value_sec(str(i),x[6],x[2],x[3],x[4],x[5]),axis=1)
    dfT=dfT.dropna()
    dfT=dfT.to_frame()
    dfT.columns=['one']
    dfT=pd.DataFrame(dfT['one'].values.tolist())
    dfT.columns=['Sector Formal'    ,'Sector Informal'  ,'Empleo Doméstico',    'No Cla
    dfTMean=dfT.describe().iloc[1:2]
    dfTMean['Anios']=i
    dfF=pd.concat([dfF,dfTMean],axis=0)

  dfF=dfF.transpose()
  dfF.columns=dfF.iloc[-1]
  dfF=dfF.iloc[:-1]
  dfF.to_csv('drive/MyDrive/Prueba/PIE.csv',encoding= 'latin1')

  return dfF

```

```
dfF= pd.read_csv("drive/MyDrive/Prueba/PIE.csv",skiprows=0, low_memory=False,encoding=
dfF.set_index('Unnamed: 0',inplace = True)
```

```
#funcion para graficar
def graficar(dataF,rang1,rang2):
  for i in range(rang1,rang2):
    my_cols=['lightgreen','lightblue','silver','red']
    dfF.plot.pie(subplots=True,y=str(i)+".0", figsize=(9, 4),startangle=45, fontsize=16


```

Grafico PIE

```
dataSecto=sectorizacion(2018,2022)
graficar(dataSecto,2018,2022)
```

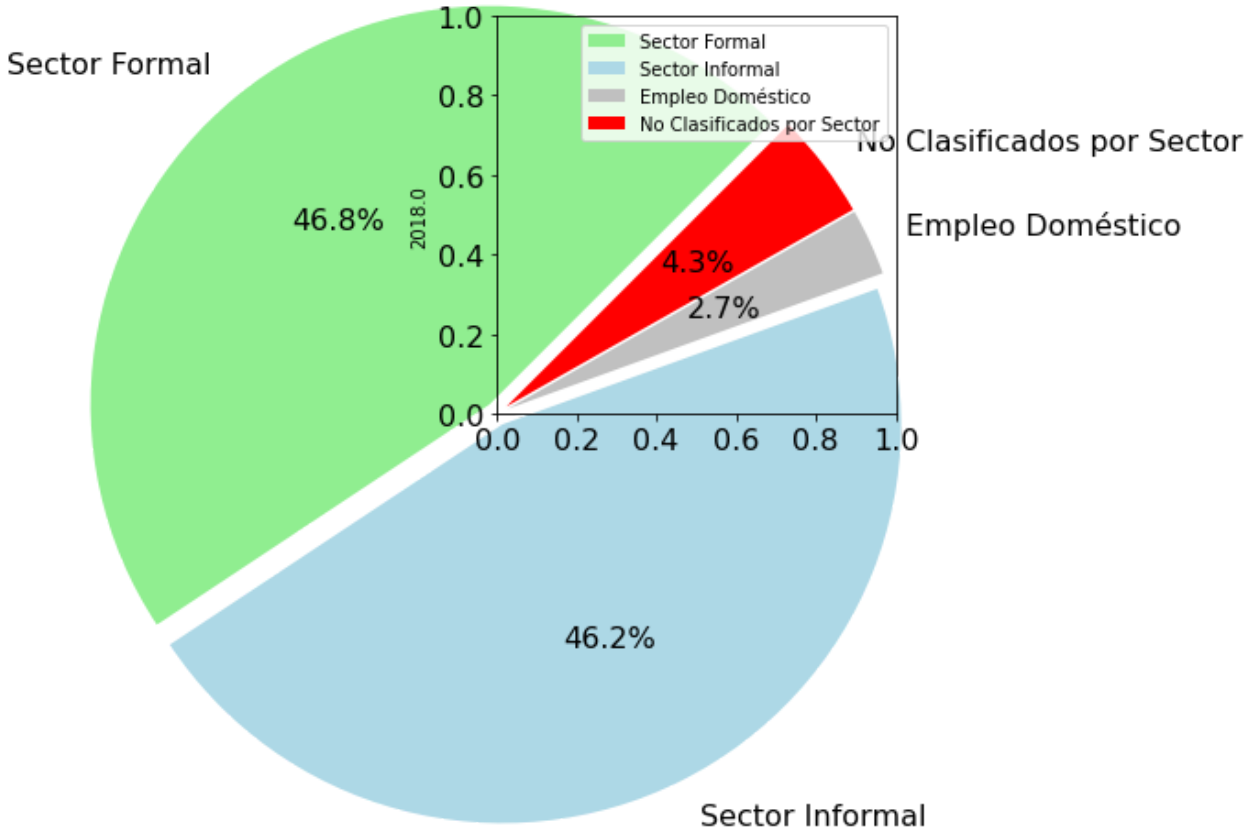
Sector Formal
Sector Informal
Empleo Doméstico
No Clasificados por Sector
46.8%
46.2%
4.3%
2.7%
2018.0

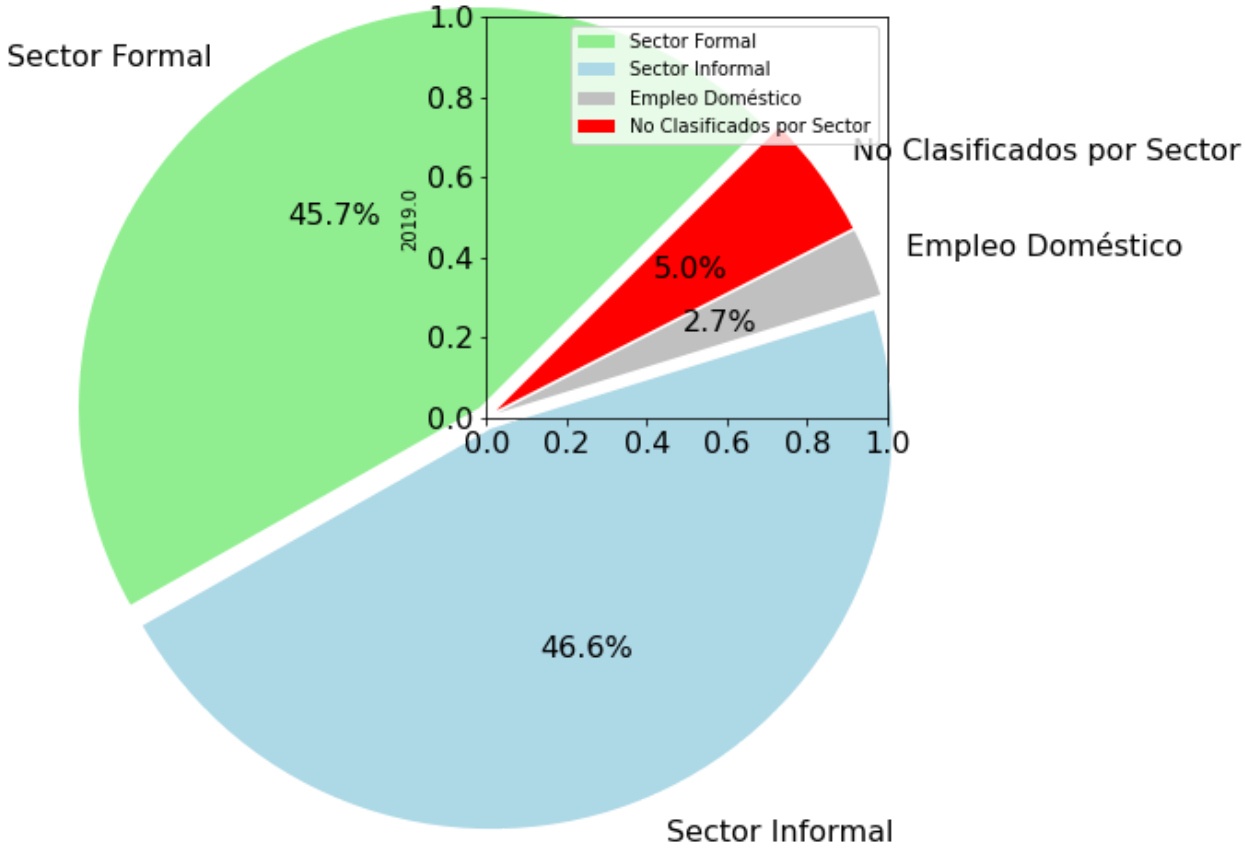
Sector Formal
Sector Informal
Empleo Doméstico
No Clasificados por Sector
45.7%
46.6%
5.0%
2.7%
2019.0

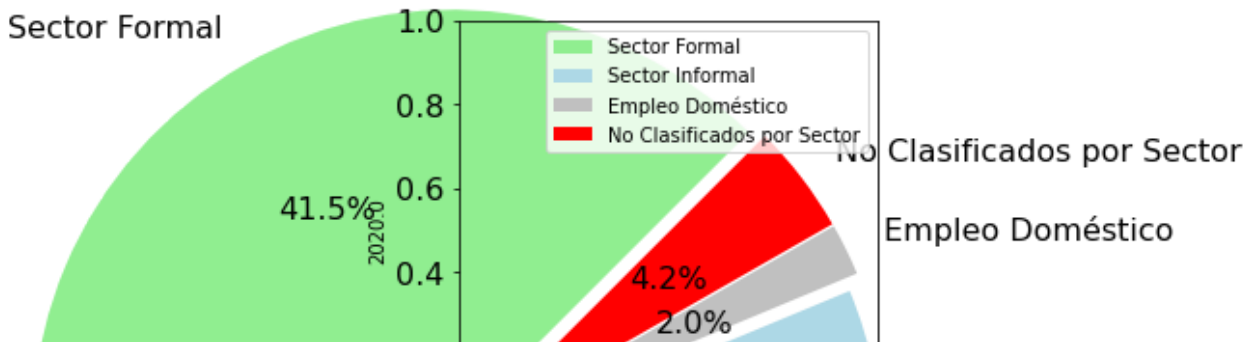
Sector Formal
Sector Informal
Empleo Doméstico
No Clasificados por Sector
41.5%
4.2%
2.0%
2020.0

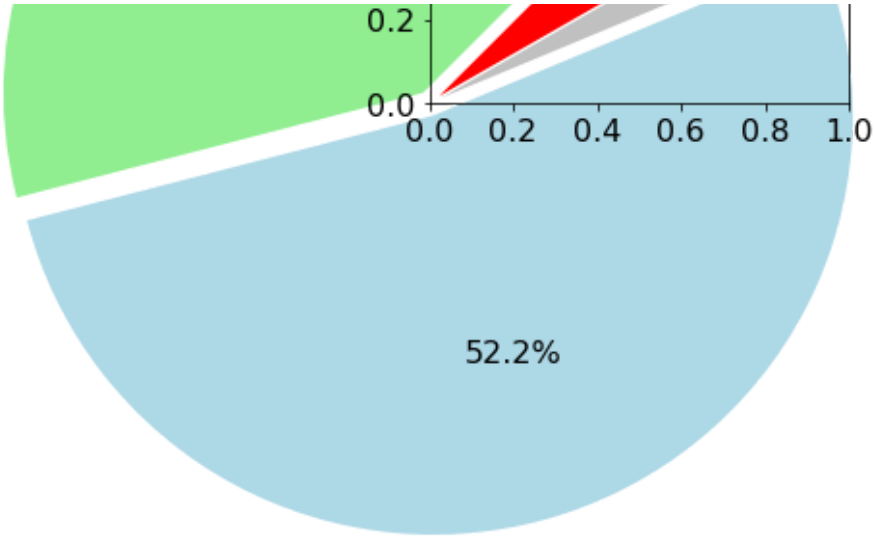

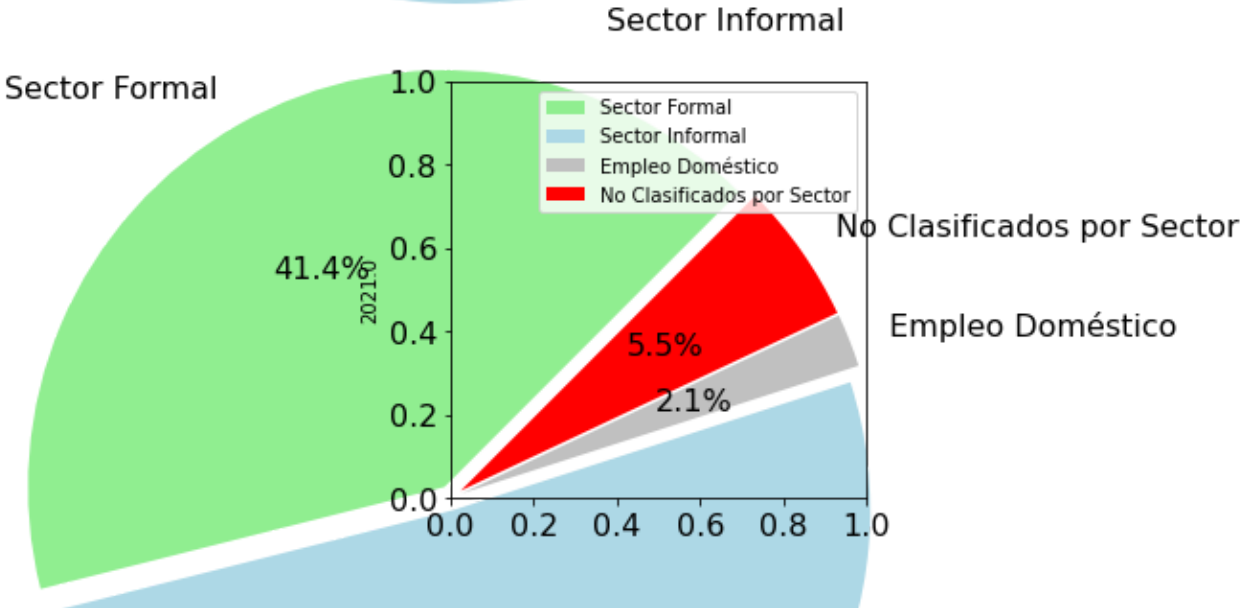

Generar histogramas subempleo, empleo pleno y empleo no pleno por año

Procedemos a extraer la información necesaria para resolver el enunciado, dicha información está disponible en el dataset de población

```
1 subempleo=poblaciones.loc[ (poblaciones['Unnamed: 2']) == 'Subempleo']
2 pleno=poblaciones.loc[ (poblaciones['Unnamed: 2']) == 'Empleo Adecuado/Pleno']
3 no_pleno=poblaciones.loc[ (poblaciones['Unnamed: 2']) == 'Otro Empleo no pleno']
```

```
1 subempleo["Anios"]=subempleo.apply(lambda x: sacAnio(x[1]), axis=1)
2 pleno["Anios"]=pleno.apply(lambda x: sacAnio(x[1]), axis=1)
3 no_pleno["Anios"]=no_pleno.apply(lambda x: sacAnio(x[1]), axis=1)
```

```
/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:1: SettingWithCopyWarnir


A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/us
```

```
/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:2: SettingWithCopyWarnir


A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/us

/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:3: SettingWithCopyWarnir


A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/us
```

- **Procedemos a concatenar toda la información en un solo dataframe**

```
data_Final=pd.concat([subempleo,pleno,no_pleno],axis=0)
data_Final=data_Final.iloc[:,[2,3,8]]
data_Final.columns=['Tipo','Total','Anios']
data_Final.head()
```

	Tipo	Total	Anios
6	Subempleo	1155872	2007
24	Subempleo	1130699	2008
42	Subempleo	957978	2008
60	Subempleo	1071615	2009
78	Subempleo	1041266	2010

- **Función de todos los años y un palabra clave que en este caso sería Subempleo, empleo pleno y no pleno**

```

```

```
def search_value(param_anio,param_tipo,key_anio,key_tipo,total):
  if param_anio==key_anio and param_tipo== key_tipo:
    return param_tipo,total,param_anio
#Esta función general nos permite obtener el data frame que buscamos en función del ran
def estadoDeEmpleo(rang1,rang2,tipo):
    dfF=pd.DataFrame(columns=['Tipo','Total','Anios'])
    for i in range(rang1,rang2):
        df_Emp=data_Final.apply(lambda x: search_value(str(i),tipo,x[2],x[0],x[1]),axis
        df_Emp=df_Emp.dropna()
        df_Emp=df_Emp.to_frame()
```

```
        df_Emp.columns=['one']
        df_Emp=pd.DataFrame(df_Emp['one'].values.tolist())
        df_Emp.columns=['Tipo','Total','Anios']
        dfF=pd.concat([dfF,df_Emp],axis=0)


    dfF[['Total']]=dfF[['Total']].astype(int)

    return dfF.groupby(['Anios'])['Total'].agg([np.average])
```

```
def graficarHisto(data):
  my_cols=['lightgreen','lightblue','red']
  data.plot(kind="barh", figsize=(16,10), title="Histograma", layout=tuple, color=my_co
```

```
df_sub=estadoDeEmpleo(2014,2022,"Subempleo")
df_pleno=estadoDeEmpleo(2014,2022,"Empleo Adecuado/Pleno")
df_no_pleno=estadoDeEmpleo(2014,2022,"Otro Empleo no pleno")

df_histograma=df_sub
df_histograma['pleno']=df_pleno.iloc[:,-1]
df_histograma['no_pleno']=df_no_pleno.iloc[:,-1]
df_histograma.rename(columns={'average':'subempleo'},inplace=True)
graficarHisto(df_histograma)
df_histograma.head()
```

Anios	subempleo	pleno	no_pleno
2014	890444.50	3391765.25	1983901.75
2015	1034029.25	3404390.25	2032688.75
2016	1437778.75	3188784.00	2070205.75
2017	1669343.50	3275341.00	1986290.00
2018	1493030.00	3249694.50	2162808.00

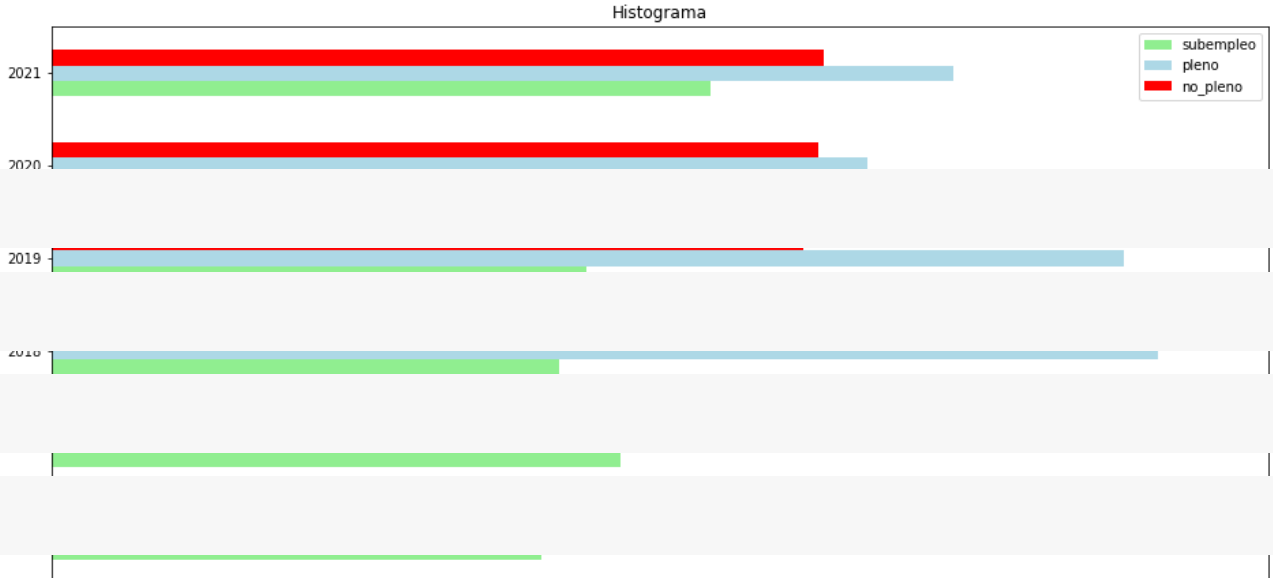

1

1

1

1

Conclusiones

Los modelos con regresiones polinómicas realizan mejores predicciones ya que se ajustan de mejor manera a los datos reales. Sin embargo, al aumentar el grado de la regresión polinómica podemos caer en un overfitting que nos arrojará resultados erróneos

Recomendaciones

Se recomienda realizar un estudio futuro para analizar el impacto de los empleos de las personas empleadas y desempeladas totalmente

✓ 0 s completado a las 3:56